كلية العلوم التطبيقية - ورزازات

FACULTE DES SCIENCES APPLIQUEES - OUARZAZATE

جامعة ابن زهر • UNIVERSITÉ IBNOU ZOHR

Department of Computer Science
Master : IAA
Course: Machine Learnin - S1

Rapport TP 1

Prétraitement des données (Dataset Titanic)

Dépôt GitHub: https://github.com/reguiyassine68-alt/Machine_learning/tree/main/titanic_training

Prepared by:

REGUI YASSINE

Supervised by:
Prof. KAMAL OMARI

Academic Year: 2026 – 2027

1. Objectif

Ce TP a pour but de préparer le dataset Titanic avant toute modélisation : exploration, nettoyage (valeurs manquantes et aberrantes), encodage, mise à l'échelle et traitement du déséquilibre des classes. La variable cible est Survived.

2. Présentation du dataset

Le dataset contient 891 passagers et 12 colonnes : PassengerId, Survived, Pclass, Name, Sex, Age, SibSp, Parch, Ticket, Fare, Cabin et Embarked. Les types sont mixtes : entiers (PassengerId, Survived, Pclass, SibSp, Parch), flottants (Age, Fare) et texte (Name, Sex, Ticket, Cabin, Embarked).
Les valeurs manquantes se trouvent dans trois colonnes :

Colonne	Valeurs manquantes
Age	177
Cabin	687
Embarked	2

3. Séparation train / test

Les données ont été séparées avec train_test_split (80 % / 20 %, random_state=42) : 712 lignes pour l'entraînement et 179 pour le test. Cette séparation est faite avant le nettoyage afin d'éviter toute fuite d'information (data leakage) : toutes les statistiques (moyenne, mode, quartiles, paramètres des scalers) sont calculées sur le train uniquement, puis appliquées au test.

Jeu	Lignes	Part
Train	712	80 %
Test	179	20 %

4. Nettoyage des données

4.1 Valeurs manquantes

Colonne	Type	Traitement
Age	Numérique	Moyenne du train
Cabin	Catégorielle (77,7 % manquant)	Supprimée (seuil 40 %)
Embarked	Catégorielle (0,28 % manquant)	Mode

Après traitement, il ne reste aucune valeur manquante dans le train ni dans le test.

4.2 Valeurs aberrantes

Les boxplots des variables numériques montrent des outliers, notamment sur Fare, SibSp et Parch. La méthode IQR a été utilisée : toute valeur hors de [Q1 − 1,5·IQR ; Q3 + 1,5·IQR] est remplacée par la médiane de la variable. Les bornes sont calculées sur le train et réutilisées sur le test.

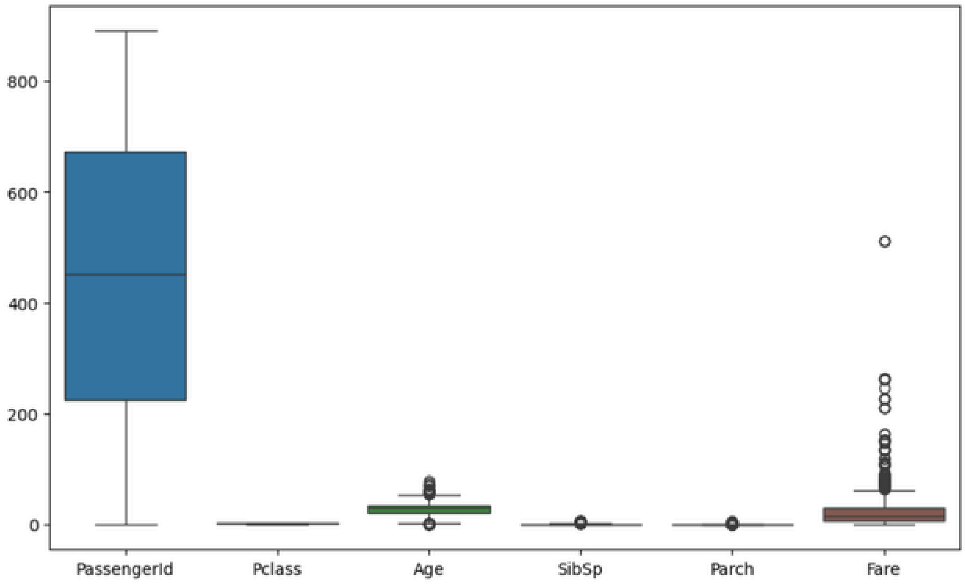

5. Encodage et mise à l’échelle

- Variables catégorielles détectées : Name, Sex, Ticket, Embarked. Embarked
- (nominale) : encodage one-hot (get_dummies, drop_first=True), avec alignement des colonnes du test sur celles du train.
- Pclass (ordinale) : déjà codée en 1, 2, 3, aucun encodage nécessaire.

Deux transformations ont été comparées sur les variables numériques :

Méthode	Résultat
Normalisation Min-Max	Valeurs dans [0, 1]
Standardisation (Z-score)	Moyenne 0, écart-type 1

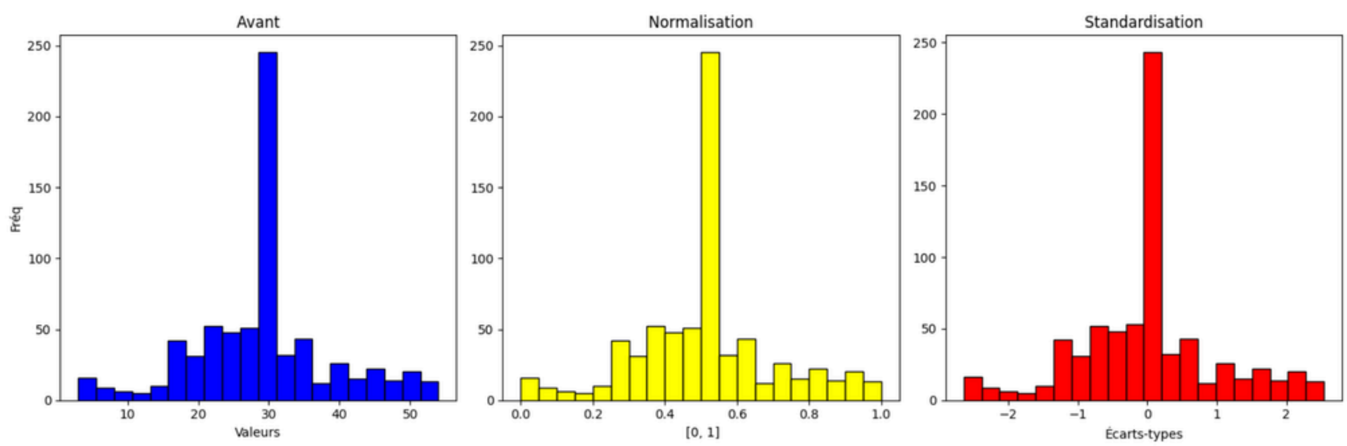

Les histogrammes de la variable Age avant/après montrent que la forme de la distribution est conservée ; seule l’échelle change. La standardisation est généralement préférable pour les modèles sensibles à l’échelle (régression logistique, SVM, KNN), la normalisation pour les réseaux de neurones.

7. Remarques et limites

- PassengerId est un simple identifiant : il ne devrait pas être traité comme variable numérique (il a été modifié par le traitement des outliers et mis à l’échelle). Il vaut mieux le supprimer
- Name et Ticket sont du texte à forte cardinalité, non encodés ; on peut les supprimer ou en extraire des informations (ex. le titre : Mr, Mrs, Miss).
- Sex, très informative pour la survie, n’a pas été encodée : SMOTE n’a donc été appliqué que sur les colonnes numériques. Il faudrait l’encoder (0/1) avant SMOTE.

- Remplacer les outliers de SibSp, Parch et Pclass par la médiane n’a pas toujours de sens : ces variables sont discrètes, et les valeurs « extrêmes » sont réelles (grandes familles).
- Les mises à l’échelle ont été faites sur x_train et non sur la version encodée x_train_encod : les deux étapes devraient être enchaînées dans un même pipeline.

8. Conclusion

Le TP a permis de dérouler la chaîne complète de prétraitement : exploration, imputation, traitement des outliers, encodage, scaling et rééquilibrage. Le jeu de données est prêt pour un premier modèle de classification, à condition de corriger les points listés ci dessus (suppression de PassengerId, encodage de Sex, enchaînement dans un pipeline) pour améliorer la qualité du modèle.